



Scaling Pod

Scaliny اذوبيه عدد ال Pods هوذا ال

Pod scaling

Manual

لما يبرود ال Pods
من خلال ال %

Automatic

VPA

HPA

يبرود ال Resources ال Pod نفسه
فيوفر استخرا الموار فقط
مش يبرود Pods ولا ينفذ

ال System بيكبر
أو يمش على مسب
ال Load

- يبرود أو يقل عدد ال Pods
لو ال Load زاد يبقى 10 Pod
لو ال Load قل يبقى 2 Pod

① بحم Condition ال على اساسه
يزود فيها ال Pods بيكون (%)

مثلا لحد 70% ولما توصل للنسبة وعاز يبرود pods يبقى هنا يجي دور ال max

بتحدد على أساس عدد ال customer اللي عندك
مثلا السيرفر بتاعي 100 pods ولما ال load يزيد ساعتها ابقى اعمل scale وخليهم 200 pod
يبقى ال max هو اعلى scale انا عاز اوصله لل pods

Max ②

Min ③

لما ال load بقى يقل اكيد مش هفضل مستهلك ال 200 pods يبقى ساعتها هحدد الحد الأدنى لل pods لما ال load يقل
وبكدا انا قدرت اتحكم بشكل automatic لما ال traffic يزيد عدد ال pods تزيد ولما ال traffic يقل عدد ال pods تقل

Pod Scaling

Kubectl create ns autoscale

Kubectl create deployment myapp --image httpd -n autoscale

Kubectl autoscale deployment myapp -n autoscale ~~cpu~~
--cpu 70% --min 3 --max 10
condition ال Pods 3 Pods 10

كمان اعدل عليه
Kubectl edit hpa myapp -n autoscale
صيفت مكانا ملف لا ابدأ بقى اعلى على كل حبة

لو عايز اشوف كل حاجة باستمرار بتعمل كسخدم أمر

~~Kubectl~~

Watch -n 1 Kubectl get Pods, hpa -n autoscale
يعني كل ثانية تتستلم

طريقة العمل لما ال Load يوصل لـ 70% هيبدأ يزنود Pod ويشوف هل ال Load قل أولا لو لما فوق ال 70% هيزنود ويشوف هل ال Load نزل ولا لا